

00S — Fundamentos de Testes de Hipóteses

Material suplementar da Cartilha Didática — Dashboard Dengue v10

Para quem é este material: Leia este módulo *antes* dos módulos 06 (Granger), 07 (ENSO) e 08 (Rolling Spearman) se você nunca estudou testes estatísticos formalmente. Ele apresenta os conceitos que esses módulos assumem como conhecidos.

Tempo estimado de leitura: 45–60 minutos.

Parte 1 — O que é uma hipótese científica?

Na ciência, uma **hipótese** é uma afirmação sobre o mundo que pode ser testada com dados. Por exemplo:

"A chuva da semana passada influencia o número de casos de dengue desta semana."

Mas como testar isso com rigor? Não basta olhar o gráfico e achar que "parece que sim". Precisamos de um procedimento formal que diga, com base nos dados, se a afirmação é sustentável ou não.

Esse procedimento é o **teste de hipóteses** — e ele funciona de uma forma um pouco contraintuitiva: em vez de tentar provar que sua hipótese é verdadeira, você tenta provar que a hipótese *oposta* é falsa.

A hipótese nula e a hipótese alternativa

Todo teste de hipóteses trabalha com um par:

	Símbolo	O que diz
Hipótese nula	H_0	"Não há efeito / não há diferença / não há relação"
Hipótese alternativa	H_1	"Há efeito / há diferença / há relação"

A H_0 é sempre a hipótese do "nada acontece". Você nunca prova que H_1 é verdadeira diretamente — você apenas tenta reunir evidência suficiente para *rejeitar* H_0 .

Intuição — O réu inocente. O sistema jurídico brasileiro presume que o réu é inocente até que se prove o contrário. O juiz não precisa provar inocência — quem precisa provar é o promotor. No teste de hipóteses, H_0 é a "inocência" (não há efeito), e os dados são as "evidências" que o promotor apresenta. Se as evidências forem fortes o suficiente, rejeita-se H_0 . Se não forem, H_0 é mantida — mas isso não significa que H_1 é falsa, apenas que os dados não foram suficientes para rejeitá-la.

Exemplos do projeto Dengue v10

Teste	H_0	H_1
ADF	A série tem raiz unitária (não-estacionária)	A série é estacionária
Granger	O passado de Chuva não ajuda a prever casos futuros	O passado de Chuva melhora a previsão de casos

Teste	H_0	H_1
Kruskal-Wallis	Os casos de dengue têm a mesma distribuição em El Niño, Neutro e La Niña	Pelo menos uma fase ENSO tem distribuição diferente
Mann-Whitney	Os casos de El Niño e La Niña têm a mesma distribuição	As distribuições são diferentes

Parte 2 — O p-valor

O **p-valor** é a peça central do teste de hipóteses, e também a mais mal interpretada da estatística.

Definição formal (e depois a intuição)

Formalização. O p-valor é a probabilidade de observar um resultado tão extremo quanto o obtido nos dados — ou ainda mais extremo — *assumindo que H_0 é verdadeira*.

Se p-valor = 0,03, isso significa: "Se H_0 fosse verdadeira (ou seja, se não houvesse nenhum efeito real), a chance de obtermos esses dados por acaso seria de apenas 3%."

Como 3% é muito pequeno, concluímos que é improvável que os dados tenham surgido por acaso sob H_0 — e **rejeitamos H_0** .

Intuição. Você está jogando uma moeda com um amigo. Ele joga 10 vezes e sai cara todas as 10 vezes. Você começa a suspeitar que a moeda é viciada. A H_0 é "a moeda é honesta". O p-valor pergunta: "Se a moeda fosse honesta, qual seria a probabilidade de sair 10 caras seguidas?" A resposta é $(1/2)^{10} = 0,001$, ou seja, 0,1%. Esse p-valor tão pequeno te leva a rejeitar H_0 — você conclui que a moeda provavelmente é viciada.

O que o p-valor NÃO é

Isso é tão importante que merece destaque:

Armadilha comum — 3 erros frequentes:

× "p = 0,03 significa que há 97% de chance de H_1 ser verdadeira." → **Errado.** O p-valor mede a probabilidade dos *dados* dado H_0 , não a probabilidade de H_1 .

× "p = 0,06 significa que o resultado é falso." → **Errado.** Significa apenas que a evidência não atingiu o limiar convencional. Pode haver um efeito real que os dados não capturaram (amostra pequena, por exemplo).

× "p = 0,001 significa que o efeito é grande." → **Errado.** Um efeito minúsculo pode ter p-valor ínfimo se a amostra for grande o suficiente. Tamanho do efeito e significância estatística são coisas diferentes.

Parte 3 — O nível de significância α

Para decidir quando rejeitar H_0 , precisamos definir *antes* do teste qual é o nosso limiar de tolerância para o erro. Esse limiar é chamado de **nível de significância**, representado pela letra grega **α** (alfa).

A convenção mais usada na ciência é $\alpha = 0,05$, o que significa:

"Aceitamos uma taxa de erro de até 5% — ou seja, em 100 testes onde H_0 é verdadeira, esperamos rejeitar H_0 erroneamente em no máximo 5 deles."

A regra de decisão é simples:

Situação	Decisão	Linguagem correta
$p\text{-valor} \leq \alpha$ (ex: $p \leq 0,05$)	Rejeitar H_0	"Resultado estatisticamente significativo"
$p\text{-valor} > \alpha$ (ex: $p > 0,05$)	Não rejeitar H_0	"Resultado não significativo"

Note: dizemos "não rejeitar H_0 ", nunca "aceitar H_0 ". A ausência de evidência contra H_0 não é evidência de que H_0 é verdadeira — pode ser simplesmente que os dados não foram suficientes.

No projeto Dengue v10. Usamos $\alpha = 0,05$ em todos os testes. Esse valor está definido em `config.py:ALPHA = 0.05` e é passado como parâmetro para todas as funções de teste em `utils/eda_avancada.py`.

Por que $\alpha = 0,05$ e não 0,01 ou 0,10?

A resposta honesta é: por convenção histórica. Ronald Fisher, estatístico britânico do século XX, sugeriu esse valor como um ponto de equilíbrio razoável entre ser exigente demais (rejeitar poucos achados verdadeiros) e ser permissivo demais (aceitar muitos falsos positivos). A ciência adotou e nunca mais largou.

Em contextos onde o erro tem consequências graves — como aprovar um medicamento — usa-se $\alpha = 0,01$ ou ainda menor. Em ciência exploratória, como o nosso projeto, $\alpha = 0,05$ é o padrão aceito.

Parte 4 — Os dois tipos de erro

Quando tomamos uma decisão com base num teste, podemos errar de duas formas:

	H_0 é verdadeira	H_0 é falsa
Rejeitamos H_0	Erro Tipo I (falso positivo) — α	Decisão correta
Não rejeitamos H_0	Decisão correta	Erro Tipo II (falso negativo) — β

Intuição com o réu. Erro Tipo I = condenar um inocente. Erro Tipo II = absolver um culpado. O sistema jurídico geralmente prefere errar pelo Tipo II (soltar um culpado) do que pelo Tipo I (prender um inocente). Na ciência exploratória, esse balanço depende do contexto.

O dilema: diminuir α (ser mais exigente) reduz o Erro Tipo I, mas aumenta o Erro Tipo II. Não há como minimizar os dois ao mesmo tempo com um tamanho de amostra fixo.

No projeto v10. Quando aplicamos a correção FDR-BH no teste de Granger (módulo 06), estamos justamente controlando o Erro Tipo I ao testar múltiplas variáveis — evitando que um falso positivo apareça por acaso entre os muitos testes simultâneos.

Parte 5 — Testes paramétricos vs. não-paramétricos

O pressuposto da normalidade

Muitos testes estatísticos clássicos — como o teste t de Student e a ANOVA — foram desenvolvidos com um pressuposto central: que os dados seguem uma **distribuição normal** (a curva em formato de sino).

Quando os dados são normalmente distribuídos, esses testes são ótimos: precisos, poderosos, bem estudados. O problema é que dados epidemiológicos raramente obedecem esse pressuposto.

Intuição. Pense na distribuição de casos semanais de dengue em Petrolina. A maioria das semanas tem zero, um ou poucos casos. Mas algumas semanas, durante um surto, chegam a centenas. Isso cria uma distribuição com uma "cauda longa" para a direita — muito diferente do sino simétrico que o teste t assume. Aplicar um teste paramétrico nesse dado é como usar uma régua para medir a temperatura: a ferramenta errada para o trabalho.

A solução: testes baseados em postos (ranks)

Os **testes não-paramétricos** resolvem esse problema de uma forma elegante: em vez de trabalhar com os valores originais dos dados, eles trabalham com a **ordem** (posto) de cada valor.

Por exemplo, se os casos em três semanas são: 5, 120, 30 — os postos são: 1, 3, 2 (do menor para o maior). O teste não-paramétrico usa os postos 1, 2, 3 em vez dos valores 5, 30, 120. Isso elimina a influência de valores extremos e torna o teste válido mesmo sem normalidade.

A desvantagem é que testes baseados em postos perdem alguma informação (a magnitude exata dos valores) — por isso, quando a normalidade é satisfeita, os testes paramétricos são preferíveis. Quando não é, os não-paramétricos são a escolha certa.

Parte 6 — A hierarquia: de onde vêm Kruskal-Wallis e Mann-Whitney?

Esta é a parte que conecta diretamente aos módulos 06 e 07 da cartilha.

O teste t de Student — comparar 2 grupos (paramétrico)

O teste t compara as médias de dois grupos e verifica se a diferença é estatisticamente significativa. Pressupõe normalidade e homogeneidade de variâncias.

Exemplo hipotético: "A média de casos é diferente em semanas de El Niño vs. semanas de Neutro?"

ANOVA — comparar 3 ou mais grupos (paramétrico)

Quando temos três ou mais grupos, o teste t não pode ser usado diretamente (testar todos os pares seria inflacionar o Erro Tipo I). A ANOVA (*Analysis of Variance*) compara todos os grupos simultaneamente.

H₀ da ANOVA: todas as médias dos grupos são iguais.

Exemplo: "As médias de casos são iguais em El Niño, Neutro e La Niña?"

Mas a ANOVA também pressupõe normalidade. Com dados de dengue, esse pressuposto é violado.

Kruskal-Wallis — a ANOVA não-paramétrica ✓ (usado no projeto)

O **Kruskal-Wallis** é a versão não-paramétrica da ANOVA. Em vez de comparar médias, ele compara as distribuições dos postos entre os grupos. Não pressupõe normalidade.

Formalização.

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1)$$

- H_0 : as distribuições dos grupos são idênticas.
- H_1 : pelo menos um grupo tem distribuição diferente.
- H segue distribuição χ^2 com $k-1$ graus de liberdade.

No projeto v10: testamos se a distribuição de `casos_est` é diferente entre as três fases ENSO. Resultado: $H = 35,8$, $p \approx 0 \rightarrow$ rejeita $H_0 \rightarrow$ as fases têm distribuições significativamente diferentes.

O problema do post-hoc: "qual par é diferente?"

Quando o Kruskal-Wallis rejeita H_0 , sabemos que *pelo menos* um par de grupos difere — mas não *qual* par. Para identificar quais grupos específicos diferem entre si, aplicamos **testes de comparação par-a-par** após o Kruskal-Wallis.

Esses testes são chamados de **post-hoc** (do latim: "depois disso"). Na ANOVA paramétrica, o post-hoc mais comum é o **Teste de Tukey**. No equivalente não-paramétrico, usamos o **Mann-Whitney U**.

A analogia direta é:

Contexto	Teste global	Teste post-hoc
Paramétrico (normalidade)	ANOVA	Tukey HSD
Não-paramétrico (sem normalidade)	Kruskal-Wallis	Mann-Whitney U ✓

Mann-Whitney U — comparar 2 grupos (não-paramétrico) ✓ (usado no projeto)

O **Mann-Whitney U** compara dois grupos verificando se um tende a ter valores maiores que o outro. Não pressupõe normalidade.

Intuição. Pegue todas as observações dos dois grupos juntas e ordene-as. Se um grupo tivesse valores sistematicamente maiores, seus postos estariam concentrados no topo da lista. O Mann-Whitney mede exatamente isso: se os postos de um grupo estão mais altos ou mais baixos do que seria esperado por acaso.

Formalização.

$$U = n_1 n_2 + \frac{n_1(n_1+1)}{2} - R_1$$

onde n_1 , n_2 são os tamanhos dos grupos e R_1 é a soma dos postos do grupo 1.

- H_0 : as distribuições dos dois grupos são iguais.
- H_1 : as distribuições são diferentes (teste bilateral).

No projeto v10: comparamos os três pares possíveis (El Niño vs. Neutro, El Niño vs. La Niña, Neutro vs. La Niña) após o Kruskal-Wallis ser significativo. Todos os três pares foram significativos, revelando o padrão El Niño > Neutro > La Niña.

Armadilha comum. Fazer múltiplos Mann-Whitney sem correção para múltiplos testes também inflaciona o Erro Tipo I — cada teste par-a-par adicional aumenta a chance de um falso positivo. Para 3 pares com $\alpha = 0,05$, a taxa de erro acumulada chega a aproximadamente 14%. No projeto v10, essa questão é mitigada pelo tamanho do efeito encontrado (todos os p-valores estão bem abaixo de 0,05, mesmo sem correção adicional) e pela natureza exploratória da análise.

O teste t de Student vs. Mann-Whitney

Assim como Kruskal-Wallis substituiu a ANOVA para 3+ grupos, o Mann-Whitney substitui o teste t para comparar apenas 2 grupos quando a normalidade não pode ser assumida:

Situação	Grupos	Pressuposto	Teste
Comparar 2 grupos	2	Normalidade ✓	t de Student
Comparar 2 grupos	2	Sem normalidade	Mann-Whitney U
Comparar 3+ grupos	≥ 3	Normalidade ✓	ANOVA
Comparar 3+ grupos	≥ 3	Sem normalidade	Kruskal-Wallis
Post-hoc paramétrico	pares	Normalidade ✓	Tukey HSD
Post-hoc não-paramétrico	pares	Sem normalidade	Mann-Whitney U

Parte 7 — O problema dos múltiplos testes

Esta parte é pré-requisito específico para entender a correção FDR-BH no módulo 06.

O problema

Imagine que você joga uma moeda honesta 20 vezes. A chance de sair cara é 50% em cada jogada. Se você jogar 20 vezes, qual é a chance de que *pelo menos uma* das jogadas pareça "suspeita" (digamos, sair cara 5 vezes seguidas)?

Na estatística, o mesmo problema aparece quando você faz muitos testes de hipóteses. Se cada teste tem 5% de chance de produzir um falso positivo (Erro Tipo I), e você faz 20 testes, espera-se que 1 deles seja falso positivo *por puro acaso*, mesmo que nenhuma hipótese seja verdadeira.


Intuição. Um detetive analisa 100 suspeitos aleatórios usando um teste que erra 5% das vezes. Em média, 5 inocentes serão erroneamente apontados como culpados. Se o detetive reportar todos como culpados sem correção, ele terá gerado 5 falsas acusações.

A solução: controle da taxa de falsas descobertas (FDR)

No projeto v10, testamos 5 variáveis climáticas no Granger. Usamos a **correção Benjamini-Hochberg (FDR-BH)** que garante que, entre todos os resultados que declaramos significativos, no máximo 5% sejam falsos positivos em média.

O procedimento é descrito em detalhes no módulo 06. O que importa entender aqui é o *porquê*: sem a correção, poderíamos declarar como "Chuva Granger-causa dengue" um resultado que na verdade é acaso estatístico entre os cinco testes feitos.

Parte 8 — Resumo visual: o fluxo de um teste de hipóteses



Parte 9 — Exercícios de fixação

Ex. S1 ★ (Conceitual)

Uma pesquisadora testa se um novo repelente reduz picadas de mosquito. Ela define: H_0 = "o repelente não tem efeito" e H_1 = "o repelente reduz picadas". O teste retorna $p = 0,03$. O que ela deve concluir? Ela provou que o repelente funciona?

Gabarito. Com $p = 0,03 < 0,05$, ela rejeita H_0 — há evidência estatística de que o repelente reduz picadas. Mas ela não "provou" que funciona no sentido absoluto: o p-valor apenas indica que seria improvável observar esses dados se o repelente não tivesse efeito. Um estudo único nunca "prova" nada — estabelece evidência. Para fortalecer a conclusão, seria necessária replicação.

Ex. S2 ★ (Conceitual)

No projeto Dengue v10, o teste de Granger para Temperatura retornou $p = 0,147$ após correção FDR. Um colega diz: "Isso prova que temperatura não influencia a dengue em Petrolina." Você concorda? Explique.

Gabarito. Não. $p > 0,05$ significa "não rejeitar H_0 ", não "aceitar H_0 ". O resultado indica que, com os dados disponíveis e o modelo linear bivariado utilizado, não há evidência suficiente para afirmar que o passado da temperatura melhora a previsão de casos. Isso pode ocorrer porque: (a) a variação semanal de temperatura em Petrolina é pequena demais para gerar sinal estatístico; (b) o efeito da temperatura é não-linear e o Granger linear não o captura; (c) o efeito está mediado por outras variáveis já no modelo. Nenhuma dessas hipóteses equivale a "temperatura não importa para o Aedes".

Ex. S3 ★★ (Conceitual)

Por que usamos Kruskal-Wallis em vez de ANOVA para comparar os casos de dengue entre as fases ENSO? E por que Mann-Whitney em vez de teste t para as comparações par-a-par?

Gabarito. Porque dados de contagem de casos de dengue têm distribuição assimétrica positiva (muitas semanas com poucos casos, alguns picos extremos) — violando o pressuposto de normalidade da ANOVA e do teste t. O Kruskal-Wallis e o Mann-Whitney trabalham com os postos (ranks) dos dados, não com seus valores originais, tornando-os válidos independentemente da distribuição. O Mann-Whitney aqui funciona como post-hoc do Kruskal-Wallis, identificando quais pares específicos de fases ENSO diferem entre si — papel análogo ao Tukey HSD no contexto paramétrico.

Ex. S4 ★★ (Formal)

O Kruskal-Wallis retornou $H = 35,8$ com $p \approx 0$. Que distribuição segue H sob H_0 ? Quantos graus de liberdade? Qual a conclusão?

Gabarito. Sob H_0 , a estatística H segue aproximadamente uma distribuição χ^2 (qui-quadrado) com $k - 1$ graus de liberdade, onde k é o número de grupos. Com $k = 3$ fases ENSO, temos 2 graus de liberdade. Com $H = 35,8$ e $p \approx 0$ (muito menor que $\alpha = 0,05$): rejeitar $H_0 \rightarrow$ pelo menos uma fase ENSO tem distribuição de casos significativamente diferente das demais. É necessário o post-hoc (Mann-Whitney) para identificar quais pares diferem.

Ex. S5 ★★ (Prático)

Você quer testar se a média de temperatura é diferente nos meses de pico de dengue (Jan–Mar) vs. os demais meses. Quais são H_0 e H_1 ? Qual teste você usaria — t de Student ou Mann-Whitney? Por quê?

Gabarito. H_0 : as distribuições de temperatura são iguais nos dois períodos. H_1 : as distribuições são diferentes. Temperatura é uma variável contínua com distribuição razoavelmente simétrica em Petrolina (pequena amplitude de variação). Em princípio, o teste t de Student poderia ser usado se a normalidade for confirmada (Shapiro-Wilk ou inspeção visual do histograma). Se houver desvio de normalidade, usa-se Mann-Whitney. Na prática, para robustez, usar Mann-Whitney sempre em dados epidemiológicos é defensável e mais conservador — especialmente num artigo onde os revisores não

questionarão o uso de um teste não-paramétrico, mas podem questionar o uso de um paramétrico sem verificação de pressupostos.

Resumo do módulo

- H_0 é a hipótese do "nada acontece". Testamos se os dados fornecem evidência para rejeitá-la.
- p-valor = probabilidade de obter os dados observados *se H_0 fosse verdadeira*. Não é a probabilidade de H_1 .
- Se $p \leq \alpha$ (convenção: $\alpha = 0,05$) → rejeitar H_0 → resultado significativo.
- Testes paramétricos (t, ANOVA) exigem normalidade. Testes não-paramétricos (Mann-Whitney, Kruskal-Wallis) funcionam com qualquer distribuição.
- Kruskal-Wallis = versão não-paramétrica da ANOVA (3+ grupos).
- Mann-Whitney = versão não-paramétrica do t de Student (2 grupos) **e** post-hoc do Kruskal-Wallis.
- Múltiplos testes → correção FDR-BH para controlar falsos positivos (módulo 06).

Este módulo é pré-requisito para: Módulo 06 (Granger + FDR-BH), Módulo 07 (Kruskal-Wallis + Mann-Whitney), Módulo 08 (Rolling Spearman).

Voltar ao índice: [00 — Índice e como usar esta cartilha](#)