

02 — Os dados

Visão geral do dataset

O dataset principal é o arquivo `dataset_semanal_petrolina.xlsx`, com **809 observações semanais** cobrindo o período de **03/01/2010 a 06/07/2025** ($\approx 15,5$ anos). Cada linha corresponde a uma semana epidemiológica de Petrolina-PE.

O dataset integra três fontes de dados:

Fonte	O que fornece	Granularidade
InfoDengue/SINAN	Casos estimados, incidência, Rt, níveis de alerta	Semana epidemiológica
INMET	Temperatura, umidade, chuva, vento, pressão, nebulosidade, insolação	Semana
NOAA/CPC	Índice ONI (ENSO)	Mês (atribuído às semanas)

As variáveis epidemiológicas

Coluna	O que mede	Tipo
<code>data_iniSE</code>	Data de início da semana epidemiológica	Data
<code>casos_est</code>	Casos de dengue <i>estimados</i> pelo InfoDengue (corrige subnotificação)	Numérico
<code>casos</code>	Casos <i>notificados</i> ao SINAN	Numérico
<code>p_rt1</code>	Probabilidade de que $R_t > 1$ (tendência de alta)	Probabilidade (0–1)
<code>p_inc100k</code>	Incidência por 100 mil habitantes	Numérico
<code>receptivo</code>	Condições ambientais favoráveis ao vetor (0–3)	Ordinal
<code>transmissao</code>	Nível de transmissão ativa (0–3)	Ordinal
<code>nivel</code>	Nível de alerta InfoDengue (1=Verde, 2=Amarelo, 3=Laranja, 4=Vermelho)	Ordinal

Atenção: `p_rt1` é a *probabilidade* de $R_t > 1$, **não** o R_t diretamente. Um valor de 0.85 significa "há 85% de chance de que a taxa de reprodução efetiva esteja acima de 1 nesta semana". Use `casos_est` como variável-alvo principal nas análises.

Por que usar `casos_est` e não `casos`?

O SINAN registra casos notificados, mas a dengue tem **alta subnotificação** — muitos casos leves não vão ao médico ou não são confirmados laboratorialmente. O InfoDengue usa modelos epidemiológicos para estimar

o total real de casos (incluindo os subnotificados). Para análises de dinâmica e correlação, **casos_est** é mais representativo da incidência real.

As variáveis climáticas

Coluna	Variável	Unidade
Temp (C)	Temperatura média	°C
Umid (%)	Umidade relativa média	%
Chuva (mm)	Precipitação acumulada	mm
Vel. Vento (m/s)	Velocidade do vento	m/s
Pressao (hPa)	Pressão atmosférica	hPa
Nebulosidade (Decimos)	Nebulosidade	Décimos de cobertura
Insolacao (h)	Insolação	Horas

As análises avançadas (Granger, VIF, MI) usam o subconjunto **nuclear**: Temperatura, Umidade, Chuva, Pressão e Vento — as variáveis com mecanismo biológico mais claro na relação com o *Aedes aegypti*.

A variável ENSO/ONI

O **ONI (Oceanic Niño Index)** é a média móvel trimestral das anomalias de temperatura da superfície do mar na região Niño 3.4 (Pacífico equatorial central). É o índice padrão do NOAA para classificar as fases do ENSO:

ONI	Fase
$\geq +0.5^{\circ}\text{C}$	El Niño
$\leq -0.5^{\circ}\text{C}$	La Niña
Entre -0.5 e $+0.5$	Neutro

Os dados ONI (2010–2025) são da fonte **NOAA/CPC ERSSTv5** e estão *hardcoded* em **config.py**, integrados ao dataset via merge mensal (cada semana recebe o ONI do mês correspondente).

No pipeline. A integração ONI é feita em **utils/data_loader.py:_build_oni_dataframe()** e **load_data()**. O merge é por mês (**data_iniSE** → período mensal → ONI correspondente). Linhas 68–82 do arquivo.

Resultado v10. No período 2010–2025, a distribuição por fase ENSO em Petrolina é: El Niño ≈ 220 semanas, Neutro ≈ 360 semanas, La Niña ≈ 229 semanas. Os anos de El Niño mais intenso foram 2015–2016 (ONI máximo: 2.8°C em Dez/2015) e 2023–2024.

Qualidade dos dados

O dataset não possui valores faltantes (nulos) em nenhuma coluna após o pré-processamento. A completude é de 100% para todas as variáveis. Isso é verificável diretamente na aba "Análise Estatística" do dashboard (seção "Completude dos Dados").

Armadilha comum. Dados sem nulos não significa dados perfeitos. Verifique sempre: (a) se há outliers extremos que possam ser erros de digitação; (b) se a escala faz sentido (temperatura de 55°C em Petrolina seria erro); (c) se há descontinuidades na série (mudança de estação de coleta, por exemplo). O módulo 03 trata disso.

Enriquecimento realizado pelo data_loader

Além das variáveis originais, o módulo `utils/data_loader.py` deriva automaticamente:

- `ano`, `mes`, `semana_epidemiologica`, `trimestre` — variáveis temporais
- `nome_mes`, `estacao` — categorias para visualização
- `nivel_categoria`, `transmissao_categoria`, `receptivo_categoria` — rótulos textuais
- `log_casos` = $\log(1 + \text{casos_est})$ — transformação para análises que assumem normalidade
- `ln_chuva` = $\log(1 + \text{Chuva})$ — chuva tem distribuição muito assimétrica
- `ENSO_fase`, `ENSO_intensidade` — classificações derivadas do ONI

Limitações dos dados

Declarar limitações não é fraqueza — é rigor científico. As principais limitações deste dataset são:

1. **Subnotificação residual:** mesmo `casos_est` do InfoDengue carrega incerteza do modelo de estimação.
2. **Dados climáticos agregados:** as variáveis do INMET são de uma estação meteorológica da cidade. Petrolina tem micro-variações climáticas (zona ribeirinha vs. periferia seca) que não são capturadas.
3. **ONI mensal para semanas:** a atribuição do ONI mensal a cada semana é uma aproximação. Transições de fase no meio do mês são suavizadas.
4. **Ausência de fatores socioambientais:** o dataset não inclui dados de saneamento, densidade vetorial, imunidade populacional, sorotipos circulantes ou intervenções de controle. Esses fatores podem ser confundidores nas relações detectadas.
5. **ONI 2025 parcialmente estimado:** dados de Jun–Dez 2025 são placeholders neutros (0.0) por ainda não estarem disponíveis na data de construção.

Para o relatório/artigo. "Os dados epidemiológicos foram obtidos do InfoDengue (casos estimados por modelo de correção de subnotificação) e do SINAN/SVS-MS. Dados meteorológicos são da estação INMET de Petrolina-PE. O índice ONI (NOAA/CPC ERSSTv5, consultado em 14/04/2026) foi atribuído a cada semana pelo mês correspondente. Limitações incluem: subnotificação residual, ausência de dados de imunidade populacional e sorotipos, e a representação climática de uma única estação de medição."

Resumo do módulo

- 809 semanas (2010–2025), três fontes integradas: InfoDengue, INMET, NOAA.
- Variável-alvo principal: `casos_est` (corrige subnotificação).
- `p_rt1` é probabilidade de $R_t > 1$, não R_t diretamente.
- ONI hardcoded em `config.py`, integrado via merge mensal.
- Dataset completo (sem nulos), mas com limitações declaradas sobre representatividade.