

## 03 — EDA Descritiva

### O que é EDA?

**EDA** (Exploratory Data Analysis — Análise Exploratória de Dados) é o conjunto de técnicas usadas para entender os dados *antes* de aplicar qualquer análise avançada. A ideia é simples: antes de perguntar "chuva causa dengue?", você precisa saber como cada variável se comporta isoladamente — qual a média, qual o espalhamento, existem valores absurdos?

Pular a EDA é como sair para dirigir sem checar o óleo do carro. Você pode chegar ao destino, mas corre riscos desnecessários.

### Estatísticas descritivas básicas

Para cada variável numérica do dataset, calculamos:

| Estatística              | Símbolo                       | O que mede                                |
|--------------------------|-------------------------------|-------------------------------------------|
| Média                    | $\bar{x}$                     | Centro da distribuição                    |
| Mediana                  | $\tilde{x}$                   | Valor do meio (menos sensível a extremos) |
| Desvio padrão            | $s$                           | Espalhamento típico em torno da média     |
| Mínimo e máximo          | $x_{min}, x_{max}$            | Extremos da distribuição                  |
| Coefficiente de variação | $CV = s/\bar{x} \times 100\%$ | Variabilidade relativa à média            |

**Intuição.** Se a média de casos por semana é 50 e o desvio padrão é 80, o CV é 160% — isso indica altíssima variabilidade (típico de epidemias com surtos). Compare com temperatura: média 26°C, desvio 3°C, CV  $\approx$  12% — muito mais estável.

**Formalização.** O coeficiente de variação é adimensional, permitindo comparar variabilidade entre variáveis em unidades diferentes.  $CV > 100\%$  geralmente indica distribuição com assimetria pronunciada e/ou outliers relevantes.

**No pipeline.** Calculado em `pages/analise_estatistica.py`, seção "Estatísticas Descritivas", linha  $\approx$  120. A coluna CV é adicionada ao `.describe()` do pandas.

### Distribuição e normalidade

Muitas técnicas estatísticas assumem que os dados seguem uma **distribuição normal** (o famoso "sino"). Na prática, contagens de casos de dengue raramente são normais — elas têm muitas semanas com poucos casos e alguns picos muito altos (distribuição com cauda longa à direita, chamada de *right-skewed*).

Por isso o pipeline usa:

- **Testes não-paramétricos** (Spearman, Kruskal-Wallis, Mann-Whitney) que não assumem normalidade.
- **Transformação log:** `log_casos = log(1 + casos_est)` comprime os picos e aproxima a distribuição da normal, útil quando necessário.

**Armadilha comum.** Aplicar um teste que assume normalidade (como o t-test de Student) em dados de contagem de casos de dengue gera resultados inválidos. Sempre verifique a distribuição dos dados antes de escolher o teste.

## Detecção de outliers

Um **outlier** (valor atípico) é uma observação muito diferente das demais. Pode ser:

- **Erro de dados:** digitação errada, falha de sensor.
- **Evento real extremo:** um surto epidêmico excepcional (e.g., o pico de 2022–2024 no Brasil).

O dashboard v10 implementa três métodos de detecção:

### Método 1 — IQR (Intervalo Interquartil)

**Intuição.** Imagine a distribuição dos dados como uma caixa. O IQR é o tamanho da caixa (do 25º ao 75º percentil). Outliers ficam "muito além" das bordas da caixa.

**Formalização.**

$$\text{IQR} = Q_3 - Q_1$$

Outlier se  $x < Q_1 - 1.5 \times \text{IQR}$  ou  $x > Q_3 + 1.5 \times \text{IQR}$

Essa é a regra padrão do boxplot de Tukey (1977). O fator 1.5 equivale a aproximadamente  $\pm 2.7\sigma$  numa distribuição normal.

### Método 2 — Z-Score

**Intuição.** Mede quantos desvios padrão um valor está da média. Um valor a mais de 3 desvios padrões é raro mesmo em distribuições muito espalhadas.

**Formalização.**

$$z = \frac{x - \bar{x}}{s}$$

Outlier se  $|z| > 3$ .

### Método 3 — Percentil 95

**Intuição.** Simplesmente marca como atípicos os 5% maiores valores. Útil para dengue, onde os picos de surto são eventos reais importantes, não erros.

**No pipeline.** Função `detectar_outliers(series, metodo)` em `utils/eda_avancada.py:400`. Métodos: "iqr", "zscore", "percentil".

**Resultado v10.** Para `casos_est`, o método IQR identifica os surtos de 2015–2016, 2019 e 2022–2024 como outliers. Esses são eventos reais (não erros) — portanto, *não removemos* esses pontos. A detecção serve para identificar e explicar, não necessariamente excluir.

## Teste de Shapiro-Wilk (normalidade)

O teste de Shapiro-Wilk verifica se uma amostra segue distribuição normal.

#### Formalização.

- $H_0$ : a amostra vem de uma distribuição normal.
- $H_1$ : a distribuição não é normal.
- Se  $p < 0.05$ : rejeitar  $H_0 \rightarrow$  não-normal.

**Armadilha comum.** Em amostras grandes (como 809 semanas), o Shapiro-Wilk rejeita  $H_0$  com facilidade — qualquer desvio pequeno de normalidade torna-se "significativo". Para dados de saúde pública em séries longas, assume-se em geral que a distribuição não é normal e usam-se testes não-paramétricos.

## O que olhar nos dados de Petrolina

Antes de avançar para as análises complexas, familiarize-se com estes fatos básicos:

- **Sazonalidade clara:** os picos de dengue ocorrem no primeiro trimestre do ano (Jan–Mar), coincidindo com o período chuvoso do semiárido.
- **Surtos excepcionais:** 2015–2016 (El Niño forte), 2019 e 2022–2024 (epidemia nacional).
- **Alta variabilidade:** o CV de `casos_est` é alto (esperado para epidemias com surtos anuais variáveis).
- **Temperatura estável:** Petrolina é quente o ano todo ( $\sim 26\text{--}32^\circ\text{C}$ ); a variação sazonal de temperatura é menor que a variação de chuva.
- **Chuva concentrada:** a maioria das semanas tem chuva próxima de zero; poucos meses concentram a maior parte da precipitação anual.

**Para o relatório/artigo.** "A análise descritiva revelou alta variabilidade nos casos estimados de dengue ( $\text{CV} > 100\%$ ), com distribuição assimétrica positiva típica de contagens epidemiológicas. A série apresenta sazonalidade pronunciada com picos no primeiro trimestre do ano. Testes de normalidade confirmaram distribuição não-normal para todas as variáveis epidemiológicas, justificando o uso de estatísticas e testes não-paramétricos."

## Resumo do módulo

- EDA descritiva é o primeiro passo obrigatório antes de qualquer análise avançada.
- Estatísticas básicas (média, mediana, desvio padrão, CV) revelam o comportamento de cada variável.
- Outliers em dengue frequentemente são surtos reais — identificar, não necessariamente remover.
- Dados de casos de dengue não são normais; use testes não-paramétricos.

---

Próximo módulo: [04 — Estrutura temporal](#) Módulo anterior: [02 — Os dados](#)