

04 — Estrutura temporal: STL, estacionariedade e ACF/PACF

Por que a estrutura temporal importa

Dados epidemiológicos semanais não são observações independentes: o número de casos esta semana depende do número de semanas anteriores (incubação, ciclo vetorial, imunidade). Antes de analisar a relação entre clima e dengue, precisamos entender a **estrutura interna** da série de casos:

- Existe uma tendência de longo prazo (subindo ou descendo ao longo de 15 anos)?
- Existe sazonalidade regular (picos todo ano no mesmo período)?
- O que sobra depois de remover tendência e sazonalidade? (resíduo)

Essas perguntas são respondidas pela **decomposição STL**.

Decomposição STL

STL significa *Seasonal-Trend decomposition using LOESS* (decomposição sazonal-tendência via LOESS). Foi proposta por Cleveland et al. (1990) e é uma das técnicas mais utilizadas para séries temporais epidemiológicas.

Intuição. Imagine que a série de casos de dengue é uma música com três instrumentos tocando ao mesmo tempo: (1) um baixo lento que representa a tendência de longo prazo, (2) um ritmo que se repete todo ano que representa a sazonalidade, e (3) um ruído de fundo que representa eventos aleatórios e irregulares. O STL "separa" os três instrumentos para que você possa ouvir cada um de forma isolada.

Formalização. A decomposição STL decompõe a série Y_t em:

$$Y_t = T_t + S_t + R_t$$

onde:

- T_t = componente de tendência (suavização LOESS de longa escala)
- S_t = componente sazonal (padrão que se repete com período fixo p)
- R_t = resíduo (o que sobra: variações não explicadas por tendência nem sazonalidade)

O algoritmo STL itera alternando a estimação de T_t e S_t via suavização LOESS (*locally estimated scatterplot smoothing*), convergindo para uma decomposição estável. A opção **robust=True** reduz o peso de outliers no ajuste.

Parâmetros usados no dashboard v10

- **period** = 52 semanas (um ano epidemiológico)
- **robust** = True (reduz influência de surtos extremos no ajuste)

No pipeline. Função `decompor_stl(series, period=52)` em `utils/eda_avancada.py:21`. Chamada em `pages/panorama_historico.py:render()`, após preparação da série com frequência semanal (`asfreq("W-SUN")`).

Resultado v10. Amplitude sazonal = **313 casos** (diferença entre pico e vale do componente sazonal anual). Desvio padrão do resíduo = **61,5 casos**. Tendência: de ≈ 40 casos/semana em 2010 para ≈ 120 casos/semana em 2025, com pico na epidemia 2022–2024. Isso indica que a série tem tendência de alta ao longo do período, sazonalidade pronunciada, e variabilidade residual moderada.

Como interpretar os componentes STL

Componente	O que observar
Tendência (T_t)	Subindo? Descendo? Aceleração após certo ano?
Sazonalidade (S_t)	Pico sempre no 1º trimestre? A amplitude varia entre anos?
Resíduo (R_t)	Picos residuais grandes = surtos não explicados pela sazonalidade habitual

Armadilha comum. Amplitude sazonal de 313 casos **não significa** que todo ano a dengue vai a 313 casos — significa que o componente sazonal varia 313 casos entre seu pico e seu vale. O número absoluto de casos num ano depende também da tendência e do resíduo.

Estacionariedade

Uma série temporal é **estacionária** quando sua média, variância e autocorrelação não mudam ao longo do tempo. Isso é importante porque muitos testes estatísticos (especialmente o teste de Granger, módulo 06) exigem estacionariedade dos dados.

Intuição. Uma série estacionária é como o nível do mar em tempo calmo: oscila, mas em torno de um nível médio estável. Uma série não-estacionária é como um rio após chuvas: o nível médio muda sistematicamente. Se você tentar correlacionar duas séries não-estacionárias que ambas sobem com o tempo, pode encontrar correlação alta *apenas porque as duas crescem juntas* — mesmo que não tenham nenhuma relação real (correlação espúria).

Teste ADF (Augmented Dickey-Fuller)

O ADF testa se a série tem uma "raiz unitária" — característica das séries não-estacionárias.

Formalização.

- **H_0 (ADF):** a série tem raiz unitária → **não-estacionária**
- **H_1 (ADF):** a série não tem raiz unitária → **estacionária**
- Se $p\text{-valor(ADF)} \leq 0.05$: rejeitar H_0 → evidência de estacionariedade.

Teste KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

O KPSS tem a hipótese *invertida* em relação ao ADF.

Formalização.

- **H_0 (KPSS):** a série é estacionária (em torno de tendência determinística)
- **H_1 (KPSS):** a série não é estacionária
- Se $p\text{-valor(KPSS)} \geq 0.05$: não rejeitar H_0 → evidência de estacionariedade.

Usando os dois testes juntos

A combinação ADF + KPSS produz conclusões mais robustas:

ADF rejeita H_0 ?	KPSS não rejeita H_0 ?	Conclusão
Sim ($p \leq 0.05$)	Sim ($p \geq 0.05$)	✓ Estacionária
Não	Não	× Não-estacionária (precisa diferenciar)
Sim	Não	⚠ Tendência determinística
Não	Sim	? Ambígua (análise adicional)

No pipeline. Função `teste_estacionariedade(series, nome)` em `utils/eda_avancada.py:50`. Retorna dicionário com estatísticas ADF/KPSS, conclusão automática e flag `diferenciacao` (se True, a série deve ser diferenciada antes do Granger).

Resultado v10. `casos_est` → **Estacionária** (ADF $p = 0.000$, KPSS $p = 0.10$). Isso significa que a série de casos flutua em torno de um nível que não deriva sistematicamente ao longo do tempo — mesmo com tendência visível, a componente estocástica (aleatória) é estacionária.

Diferenciação

Se uma série não-estacionária é identificada, aplica-se a **diferenciação**: em vez de analisar Y_t , analisa-se $\Delta Y_t = Y_t - Y_{t-1}$ (a variação semana a semana). Isso remove tendências lineares e torna a série estacionária.

No pipeline. Função `preparar_serie_granger(series, diferenciar)` em `utils/eda_avancada.py:88`.

ACF e PACF

ACF (AutoCorrelation Function) e **PACF** (Partial AutoCorrelation Function) mostram como uma série se correlaciona com suas próprias versões defasadas.

Intuição. Se a ACF mostra alta correlação no lag 52 (52 semanas = 1 ano), significa que saber o nível de dengue desta semana do ano passado ajuda a prever o nível desta semana — sazonalidade. Se a correlação diminui lentamente (não cai rapidamente), isso é sinal de não-estacionariedade.

A ACF e PACF aparecem no dashboard v10 na aba "Análise Estatística". Elas são ferramentas de diagnóstico, não de inferência — não há p-valor, mas o padrão visual informa muito sobre a estrutura da série.

Para o relatório/artigo. "A decomposição STL (Cleveland et al., 1990; period=52, robust=True) revelou amplitude sazonal de 313 casos e desvio padrão do resíduo de 61,5, indicando sazonalidade pronunciada com pico no primeiro trimestre. Os testes ADF ($p < 0.001$) e KPSS ($p = 0.10$), aplicados conjuntamente conforme Kwiatkowski et al. (1992), classificaram `casos_est` como série estacionária, dispensando diferenciação antes dos testes de Granger."

Resumo do módulo

- STL decompõe a série em Tendência + Sazonalidade + Resíduo. Amplitude sazonal = 313 casos em Petrolina.
- Estacionariedade é pré-requisito para o Granger. ADF e KPSS combinados dão conclusão mais robusta.

- `casos_est` é estacionária (ADF $p \approx 0$, KPSS $p = 0.10$).
 - Série não-estacionária → aplicar diferenciação antes do Granger.
-

Próximo módulo: [05 — Relação clima-dengue](#) **Módulo anterior:** [03 — EDA descritiva](#)