

05 — Relação clima-dengue: CCF, correlação parcial, VIF e MI

A cadeia de evidências

Antes de testar "causalidade de Granger" (módulo 06), precisamos estabelecer a evidência de *associação*: existe correlação estatisticamente significativa entre as variáveis climáticas e os casos de dengue? Em que defasagem temporal (*lag*)?

Este módulo cobre quatro ferramentas complementares para isso:

1. **CCF Bootstrap** — qual lag mostra maior correlação, com intervalo de confiança confiável?
2. **Correlação Parcial** — a correlação de Chuva com dengue é real, ou é artefato da correlação de Chuva com Temperatura?
3. **VIF** — as variáveis climáticas carregam informação redundante entre si?
4. **Informação Mútua** — existe dependência *não-linear* que Spearman/Pearson perde?

CCF — Cross-Correlation Function com IC Bootstrap

O problema do IC analítico

A CCF mede a correlação cruzada entre duas séries em diferentes lags. O problema é: como saber se uma correlação de $r = 0.15$ no lag 6 é "significativa" ou apenas ruído?

A fórmula analítica padrão para o IC é $\pm 1.96/\sqrt{n}$, mas ela assume que a série de referência é **ruído branco** (sem autocorrelação). Séries de dengue têm forte autocorrelação (esta semana se parece com a semana passada) — isso invalida o IC analítico e pode gerar falsos positivos.

Solução: Bootstrap por permutação circular

Intuição. Para saber o que seriam "correlações aleatórias" entre chuva e dengue, podemos embaralhar os dados de chuva e recalculá-la CCF muitas vezes. Mas embaralhar aleatoriamente destrói a autocorrelação da série. A solução é o embaralhamento *circular*: deslocar a série inteira por um número aleatório de posições, como se ela fosse um anel girando. Assim a autocorrelação interna é preservada, mas a relação temporal com dengue é destruída.

Formalização. O bootstrap circular gera a distribuição nula das correlações:

Para $b = 1, \dots, B$ (com $B = 1000$):

1. Sortear deslocamento $k_b \sim \text{Uniforme}(1, n - 1)$
2. Calcular $\tilde{x}_b = \text{roll}(x, k_b)$ (rotacionar a série circular)
3. Calcular $\text{CCF}(\tilde{x}_b, y)$ para todos os lags

O intervalo de confiança 95% é dado pelos percentis 2.5% e 97.5% das B correlações em cada lag.

$$CI_{lag} = [q_{0.025}(\{\text{CCF}(\tilde{x}_b, y)\}_{b=1}^B), q_{0.975}(\{\text{CCF}(\tilde{x}_b, y)\}_{b=1}^B)]$$

Uma correlação observada r_{lag} é considerada significativa se $r_{lag} > CI_{upper,lag}$ ou $r_{lag} < CI_{lower,lag}$.

No pipeline. Função `ccf_bootstrap(x, y, nlags=12, n_boot=1000, alpha=0.05, seed=42)` em `utils/eda_avancada.py:100`. A permutação circular usa `np.roll(x, shift)` (linha 127). O `seed=42` garante reprodutibilidade.

Resultado v10. Lags ótimos (maior $|r|$ significativo):

Variável	Lag ótimo	Correlação	Significativo
Chuva (mm)	6 semanas	~0.35	Sim
Umidade (%)	4–6 semanas	~0.28	Sim
Temperatura (°C)	1–2 semanas	~0.18	Sim/marginal
Pressão (hPa)	1–2 semanas	~-0.15	Sim/marginal
Vento (m/s)	1 semana	~-0.12	Variável

Interpretação biológica do lag 6 de Chuva

O lag de 6 semanas para Chuva → Casos corresponde ao **ciclo biológico do *Aedes aegypti***:

- A chuva cria e mantém criadouros (recipientes com água parada).
- Os ovos eclodem e os mosquitos se desenvolvem em ≈ 10 –14 dias.
- O mosquito infectado tem período de incubação extrínseca de ≈ 7 –14 dias.
- O humano infectado tem período de incubação de ≈ 4 –7 dias antes dos sintomas.
- O caso é notificado/registrado com mais alguns dias de atraso.

Somando: 2 + 1,5 + 0,8 + 1 semana $\approx$ **5–6 semanas** entre chuva e registro do caso. O resultado estatístico bate com a biologia — isso é evidência de plausibilidade.

Correlação Parcial

O problema da confusão

Temperatura e Chuva estão correlacionadas entre si (no semiárido, os meses quentes e chuvosos coincidem). Isso significa que a correlação de Chuva com Dengue pode ser "puxada" pela correlação de Temperatura com Dengue — ou vice-versa. Para isolar o efeito independente de cada uma, usamos **correlação parcial**.

Intuição. Você quer saber se o chocolate realmente aumenta a inteligência. Mas pessoas ricas comem mais chocolate e têm mais acesso à educação. A correlação direta chocolate-inteligência pode ser espúria (causada pela renda). A correlação parcial controla pela renda e mede só o efeito direto do chocolate.

Formalização. A correlação parcial de X com Y controlando por Z é:

1. Regride Y contra Z ; guarda os resíduos e_Y .
2. Regride X contra Z ; guarda os resíduos e_X .
3. Calcula a correlação de Pearson entre e_Y e e_X .

O resultado é a correlação entre X e Y depois de "remover" o efeito linear de Z de ambos.

No pipeline. Função `correlacao_parcial(df, target, predictor, controls)` em `utils/eda_avancada.py:268`. Usa regressão por mínimos quadrados (`np.linalg.lstsq`) para calcular os resíduos.

Resultado v10. Correlação parcial de Chuva com Casos, controlando Temperatura: $r = 0.088$, $p = 0.012$ (significativa). Isso confirma que a chuva tem efeito independente da temperatura — mesmo que a temperatura esteja controlada, a chuva ainda explica parte da variação nos casos.

VIF — Variance Inflation Factor

O problema da colinearidade

Se vamos usar múltiplas variáveis climáticas juntas num modelo (por exemplo, para o Granger), é importante verificar se elas são muito parecidas entre si (colineares). Variáveis colineares fornecem informação redundante e podem distorcer as estimativas.

Intuição. Imagine que você quer medir a sua altura usando duas réguas. Se as duas réguas marcam exatamente o mesmo número, uma delas é redundante. No caso das variáveis climáticas, se Temperatura e Insolação variam sempre juntas, elas são "quase a mesma régua" — colineares.

Formalização. Para cada variável X_j , o VIF é:

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

onde R_j^2 é o coeficiente de determinação da regressão de X_j contra todas as demais variáveis climáticas.

- $\text{VIF} = 1$: nenhuma colinearidade
- $\text{VIF} > 5$: colinearidade moderada (alerta)
- $\text{VIF} > 10$: colinearidade severa (problema)

No pipeline. Função `calcular_vif(df, cols)` em `utils/eda_avancada.py:243`. Usa `variance_inflation_factor` do `statsmodels`.

Resultado v10. Todos os VIFs das variáveis climáticas nucleares ficaram **abaixo de 3** — sem colinearidade severa. Isso indica que as variáveis fornecem informação razoavelmente independente, e podemos usá-las juntas no Granger sem problemas de inflação de variância.

Armadilha comum. VIF alto (> 10) não significa que uma variável não importa — significa que ela é difícil de separar das outras estatisticamente. Se você enfrenta VIF alto, ou remove a variável mais colinear, ou usa técnicas de regularização (Ridge, Lasso).

Informação Mútua

Dependências não-lineares

Pearson e Spearman medem relações *lineares* ou *monotônicas* (onde uma sempre sobe quando a outra sobe). Mas e se a relação fosse em forma de "U" — dengue alta tanto com muito calor quanto com frio moderado?

Pearson daria $r \approx 0$ mesmo havendo uma relação real.

Informação Mútua (MI) mede qualquer tipo de dependência estatística — linear ou não.

Intuição. MI mede: "se eu souber o valor de X, quanto menos incerto fico sobre Y?" Se saber a chuva da semana passada não reduz minha incerteza sobre casos futuros, $MI = 0$. Se reduz muito, MI é alto. Não importa se a relação é reta, curva ou em escada.

Formalização. Para variáveis contínuas, a Informação Mútua é estimada como:

$$MI(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

O dashboard usa o estimador k -NN ($k=5$ vizinhos mais próximos) do `sklearn`, que não assume nenhuma distribuição paramétrica.

No pipeline. Função `calcular_informacao_mutua(df, target_col, feature_cols)` em `utils/eda_avancada.py:307`. Usa `mutual_info_regression` do scikit-learn com `random_state=42, n_neighbors=5`.

Para o relatório/artigo. "A análise de associação clima-dengue empregou CCF com intervalo de confiança bootstrap (1.000 permutações circulares, IC 95%), correlação parcial de Pearson para controlar confundidores climáticos, VIF para diagnóstico de colinearidade, e Informação Mútua estimada por k -NN (scikit-learn) para capturar dependências não-lineares. O lag ótimo de Chuva → Casos de 6 semanas é consistente com o ciclo biológico documentado do *Aedes aegypti*."

Resumo do módulo

- CCF Bootstrap (permutação circular) gera ICs mais confiáveis que o IC analítico para séries com autocorrelação.
- Lag ótimo Chuva → Casos = 6 semanas, biologicamente plausível pelo ciclo do Aedes.
- Correlação parcial Chuva|Temperatura = 0.088 ($p=0.012$): efeito independente da chuva confirmado.
- VIF < 3 para todas as variáveis nucleares: sem colinearidade severa.
- MI complementa Spearman/Pearson capturando dependências não-lineares.

Próximo módulo: 06 — Causalidade de Granger **Módulo anterior:** 04 — Estrutura temporal