

06 — Causalidade de Granger

O que é causalidade de Granger?

A correlação mostra que X e Y andam juntos. Mas será que o passado de X ajuda a *prever* o futuro de Y, além do que o próprio passado de Y já conta?

Isso é o que o teste de **Causalidade de Granger** (Granger, 1969) mede — e é por isso que ele é mais poderoso que uma simples correlação para entender relações temporais.

Intuição. Imagine que você quer saber se as previsões do tempo ajudam a prever o movimento de uma enxurrada. Se você já sabe o nível do rio de ontem e de anteontem, a previsão do tempo de ontem *acrescenta* alguma coisa para prever o nível de amanhã? Se sim, dizemos que "previsão do tempo Granger-causa o nível do rio". Note: não é causalidade filosófica plena — é precedência preditiva. A enxurrada pode ter outras causas (desmatamento, falta de drenagem) que o modelo não captura.

A lógica do teste

O teste de Granger compara dois modelos:

Modelo restrito (só o passado de Y):

$$Y_t = \alpha + \sum_{k=1}^p \beta_k Y_{t-k} + \varepsilon_t$$

Modelo irrestrito (passado de Y + passado de X):

$$Y_t = \alpha + \sum_{k=1}^p \beta_k Y_{t-k} + \sum_{k=1}^p \gamma_k X_{t-k} + \varepsilon_t$$

Formalização. O teste usa a estatística F para verificar se os coeficientes γ_k são conjuntamente diferentes de zero:

- **H₀:** $\gamma_1 = \gamma_2 = \dots = \gamma_p = 0 \rightarrow X$ não Granger-causa Y
- **H₁:** pelo menos um $\gamma_k \neq 0 \rightarrow X$ Granger-causa Y

$$F = \frac{(RSS_R - RSS_{IR})/p}{RSS_{IR}/(n - 2p - 1)}$$

onde RSS_R e RSS_{IR} são as somas dos quadrados dos resíduos dos modelos restrito e irrestrito, respectivamente, e p é o número de lags.

Se p-valor < 0.05 $\rightarrow$ rejeitar $H_0 \rightarrow X$ Granger-causa Y.

Pré-requisito: estacionariedade

O teste de Granger pressupõe que as séries são **estacionárias** (ver módulo 04). Aplicar Granger em séries não-estacionárias gera resultados espúrios — você pode encontrar "causalidade" onde há apenas tendência

comum.

O pipeline v10 automatiza isso:

1. Roda ADF + KPSS para cada série.
2. Se a série for não-estacionária, aplica diferenciação ($\Delta Y_t = Y_t - Y_{t-1}$).
3. Só então roda o Granger.

Armadilha comum. Pular o teste de estacionariedade e rodar Granger direto é o erro mais comum em análises de séries temporais epidemiológicas. Se sua série de casos tem tendência de alta (como a dengue no Brasil nos últimos anos) e sua série de chuva também tem tendência sazonal, você vai encontrar "causalidade" que é apenas correlação espúria entre duas tendências.

Seleção do lag ótimo

O teste de Granger precisa de um número de lags p . O pipeline testa todos os lags de 1 a `MAX_LAG_GRANGER = 8` semanas e seleciona aquele com **menor p-valor** — o lag onde a evidência de causalidade é mais forte.

No pipeline. Função `granger_causalidade(df, target_col, causa_col, max_lag=8, ...)` em `utils/eda_avancada.py:162`. A linha 184 seleciona o lag com `min(gc.keys(), key=lambda l: gc[l][0]["params_ftest"][1])`.

O problema dos múltiplos testes

No dashboard v10, testamos 5–6 variáveis climáticas simultaneamente. Se o nível de significância é 5%, e testamos 6 variáveis independentes, esperamos encontrar **pelo acaso** $6 \times 0.05 \approx 0.3$ "significativas" mesmo que nenhuma realmente Granger-cause a dengue. Se testarmos mais, esse número sobe.

Isso é o **problema dos múltiplos testes** (*multiple comparisons problem*). A solução é aplicar uma **correção** que ajusta os p-valores.

Correção FDR-BH (Benjamini-Hochberg)

A correção **FDR** (*False Discovery Rate* — Taxa de Falsas Descobertas) de Benjamini & Hochberg (1995) controla a proporção esperada de falsas descobertas entre todos os testes declarados significativos.

Intuição. Imagine que você testou 20 variáveis e encontrou 5 com $p < 0.05$. Quantas dessas 5 são realmente verdadeiras e quantas são coincidências? O FDR-BH garante que, em média, no máximo 5% das que você declarar significativas sejam falsas descobertas.

Formalização. O procedimento FDR-BH:

1. Ordenar os p-valores dos m testes em ordem crescente: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$
2. Encontrar o maior k tal que:

$$p_{(k)} \leq \frac{k}{m} \times \alpha$$

3. Rejeitar H_0 para todos os testes com $p_{(i)} \leq p_{(k)}$.

A correção gera p-valores ajustados p^{FDR} . Um teste é significativo se $p^{FDR} \leq \alpha$.

No pipeline. Função `granger_multiplo_fdr(df, target_col, causa_cols, ...)` em `utils/eda_avancada.py:198`. A correção usa `multipletests(..., method="fdr_bh")` do `statsmodels` (linha 227).

Resultado v10. Após correção FDR-BH ($\alpha = 0.05$):

Variável	Lag ótimo	F-stat	p-valor bruto	p-valor FDR	Significativo?
Chuva (mm)	6	alto	≈ 0.000	≈ 0.000	✓ Sim
Umidade (%)	4	alto	0.00007	~ 0.0002	✓ Sim
Pressão (hPa)	1	moderado	0.019	~ 0.048	✓ Sim
Vento (m/s)	1	moderado	0.019	~ 0.048	✓ Sim
Temperatura (°C)	variável	baixo	> 0.05	> 0.05	× Não
ONI	variável	baixo	> 0.05	> 0.05	× Não

Armadilha comum. Temperatura não sendo Granger-significativa *não significa* que a temperatura não influencia a dengue. Pode significar que a relação não é linear, ou que o efeito da temperatura já está capturado indiretamente pela umidade e chuva. O resultado de Granger é sempre condicional ao modelo linear bivariado testado.

Limitações do teste de Granger

O Granger é uma ferramenta poderosa, mas tem limitações claras:

1. **Testa precedência linear:** o modelo subjacente é linear. Relações não-lineares podem não ser detectadas.
2. **Bivariado:** o pipeline testa cada variável climática isoladamente contra dengue. Numa análise multivariada (todos os climas de uma vez), os resultados podem mudar.
3. **In-sample:** Granger é um teste de ajuste em amostra (in-sample), não de previsão fora de amostra (OOS). Um resultado Granger-significativo não garante que a variável climática vá melhorar previsões futuras.
4. **Não é causalidade real:** a denominação "causalidade" é histórica. O que o teste mede é *precedência preditiva linear*.

Para o relatório/artigo. "Testes de causalidade de Granger (Granger, 1969) foram aplicados com seleção de lag por menor p-valor (máximo: 8 semanas), após verificação de estacionariedade ADF+KPSS. A correção FDR-BH (Benjamini & Hochberg, 1995) foi aplicada para controlar a taxa de falsas descobertas nos testes simultâneos das cinco variáveis climáticas nucleares. Chuva (lag 6, $p \approx 0$), Umidade (lag 4, $p \approx 0.00007$), Pressão e Vento (lag 1, $p \approx 0.019$) apresentaram causalidade de Granger significativa. Temperatura e ONI não foram significativos isoladamente. Esses resultados indicam precedência preditiva linear, não causalidade no sentido estrito."

Resumo do módulo

- Granger testa se o passado de X melhora a previsão de Y além do que o passado de Y já explica.
- **Pré-requisito obrigatório:** estacionariedade (ADF+KPSS antes do Granger).
- **Correção FDR-BH** para múltiplos testes — evita falsos positivos ao testar várias variáveis.

- Resultado v10: Chuva (lag 6), Umidade (lag 4), Pressão e Vento (lag 1) são Granger-significativos.
 - Temperatura e ONI isolados não foram significativos — mas o ENSO tem efeito modulador (módulo 07).
-

Próximo módulo: [07 — Modulação ENSO](#) **Módulo anterior:** [05 — Relação clima-dengue](#)