

10 — Reprodutibilidade

Por que reprodutibilidade importa

Um resultado científico só é confiável se outra pessoa consegue chegar ao mesmo resultado seguindo os mesmos passos. Isso é o princípio da **reprodutibilidade** — um dos pilares da ciência. No contexto de periódicos nacionais B1/B2, é cada vez mais comum (e esperado) que o código-fonte e os dados sejam disponibilizados junto com o artigo.

Como rodar o dashboard v10

```
# 1. Criar ambiente virtual
python -m venv .venv
source .venv/bin/activate      # Linux/Mac
# .venv\Scripts\activate      # Windows

# 2. Instalar dependências
pip install -r requirements.txt

# 3. Colocar o dataset na pasta data/
mkdir -p data
cp /caminho/para/dataset_semanal_petrolina.xlsx data/

# 4. Executar
streamlit run app.py
```

Dependências principais

As bibliotecas mais importantes e seus papéis no projeto:

Biblioteca	Versão recomendada	Uso no projeto
streamlit	≥ 1.30	Interface do dashboard
pandas	≥ 2.0	Manipulação do dataset
numpy	≥ 1.24	Operações numéricas
scipy	≥ 1.11	Testes estatísticos (Kruskal, Mann-Whitney, Pearson, Spearman)
statsmodels	≥ 0.14	STL, ADF, KPSS, Granger, VIF
scikit-learn	≥ 1.3	Informação Mútua (<code>mutual_info_regression</code>)
plotly	≥ 5.17	Gráficos interativos

Biblioteca	Versão recomendada	Uso no projeto
<code>openpyxl</code>	≥ 3.1	Leitura do arquivo Excel

Estrutura de arquivos

```

dashboard_v10/
├── app.py                # Ponto de entrada – 5 abas
├── config.py             # Parâmetros globais + ONI_DATA
├── requirements.txt       # Dependências
├── data/
│   └── dataset_semanal_petrolina.xlsx
├── utils/
│   ├── data_loader.py    # Carga + ONI merge
│   └── eda_avancada.py    # STL, ADF/KPSS, CCF, Granger, VIF, MI,
Rolling Spearman
│   ├── metricas.py       # KPIs para painel de situação
│   └── export.py         # Exportação de dados
├── components/
│   ├── charts.py         # Gráficos Plotly
│   └── layout.py         # CSS e componentes de layout
├── pages/
│   ├── panorama_historico.py # STL + sazonalidade
│   ├── clima_dengue.py     # CCF, Granger, VIF, MI, corr parcial
│   ├── enso_dengue.py     # ENSO, Kruskal-Wallis, Mann-Whitney
│   └── analise_estatistica.py # Rolling Spearman, estacionariedade,
outliers
    └── educacional_exportacao.py

```

Seeds e reprodutibilidade numérica

Para garantir que os resultados numéricos sejam idênticos em diferentes execuções:

- `ccf_bootstrap`: usa `seed=42` → `np.random.default_rng(42)`
- `calcular_informacao_mutua`: usa `random_state=42`
- O dataset ONI está hardcoded em `config.py` (não depende de download externo)

No pipeline. A seed do bootstrap CCF está em `utils/eda_avancada.py:113`. A seed da MI está em `utils/eda_avancada.py:316`.

Checklist de reprodutibilidade para publicação

Antes de submeter o artigo, verifique:

- ☐ O dataset está disponível para revisores (repositório público ou material suplementar)?
- ☐ Os valores ONI hardcoded em `config.py` correspondem à fonte citada (NOAA/CPC ERSSTv5, consultado em 14/04/2026)?
- ☐ O `requirements.txt` especifica as versões das bibliotecas?
- ☐ Os seeds de aleatoriedade estão fixados (42)?

- ☐ Os parâmetros de análise estão em `config.py` ($\alpha=0.05$, `MAX_LAG_CCF=12`, `MAX_LAG_GRANGER=8`, `N_BOOT_CCF=1000`, `ROLLING_WINDOW=52`, `STL_PERIOD=52`)?
- ☐ Os resultados do dashboard foram comparados com os valores reportados na cartilha (Resultado v10)?

Versionamento com Git

Boas práticas de versionamento para o projeto:

```
git init
git add .
git commit -m "Dashboard v10 — EDA avançada dengue Petrolina"
git tag v10.0
```

Use tags para marcar os estados do código correspondentes a resultados reportados no artigo. Se você corrigir um bug após submeter o artigo, crie uma nova tag (v10.1) e documente a diferença.

Dados ONI: fonte e citação

A citação correta para os dados ONI usados no projeto é:

NOAA Climate Prediction Center. *Oceanic Niño Index (ONI)* — *ERSSTv5*. Disponível em: https://www.cpc.ncep.noaa.gov/products/analysis_monitoring/ensostuff/ONI_v5.php. Acessado em: 14 de abril de 2026.

Changelog v9 → v10

Para transparência histórica do projeto:

Removido da v9:

- Modelagem preditiva: Regressão Linear, Polinomial, Random Forest
- Validação cruzada temporal (TimeSeriesSplit)
- Métricas de forecasting (RMSE, MAE, R^2)

Adicionado na v10:

- Decomposição STL (period=52, robust=True)
- CCF com IC bootstrap (1.000 permutações circulares)
- Causalidade de Granger (FDR-BH) com diferenciação automática
- VIF entre variáveis climáticas
- Correlação parcial
- Informação Mútua (sklearn)
- Rolling Spearman (janela 52 semanas)
- Aba ENSO completa (Kruskal-Wallis, Mann-Whitney, estratificação)
- Testes ADF + KPSS combinados

Justificativa: A EDA avançada é mais adequada ao escopo do PIBIC Jr e gera achados publicáveis em B1/B2 sem a sobrecarga metodológica da modelagem ML com hiperparâmetros.

Para o relatório/artigo. "O código-fonte do dashboard está disponível em [repositório]. Todas as análises foram implementadas em Python 3.11+, com seeds de aleatoriedade fixadas para reprodutibilidade (seed=42). Os parâmetros de análise estão centralizados em `config.py` para facilitar a auditoria e replicação."

Resumo do módulo

- Reprodutibilidade é requisito para publicação científica e para auditar os resultados.
- Seeds fixas (42) garantem que bootstrap e MI produzam os mesmos resultados em qualquer máquina.
- ONI hardcoded em `config.py` elimina dependência de download externo.
- O changelog v9 → v10 documenta as decisões metodológicas que levaram à versão atual.

Módulo anterior: [09 — Síntese dos achados](#) **Voltar ao início:** [00 — Índice](#)